

La falsification comme code : des critères de succès gelés par empreinte, et neuf façons dont un critère pré-enregistré échoue quand même

Édouard Lantenois*

Août 2026

Résumé

Le pré-enregistrement est d'ordinaire un document. Nous rapportons un protocole en service où il est une *empreinte* : le bloc des critères de succès vit dans le docstring du script d'analyse lui-même, il est gelé par SHA-256 avant exécution, et un vérificateur fait échouer la chaîne d'intégration s'il a bougé depuis. Les amendements restent possibles, mais publics. Sur un corpus de cosmologie — 88 critères gelés, 198 entrées numérotées au registre, 78 attaques arbitrées — le protocole s'est comporté tout autrement que prévu. Il n'a pas principalement attrapé des *résultats faux* ; il a attrapé des *critères mal posés*. Nous en donnons une taxonomie en neuf modes, chacun avec l'exemple réel qui l'a révélé : un critère portant sur un paramètre non identifiable ; une borne inadaptée au découpage des données ; une comparaison à une référence non optimisée ; le mauvais comparant ; un minimum de bord sur une branche fermée ; deux exigences mutuellement incompatibles gelées ensemble ; un docstring affirmant 60 000 points de grille quand son propre code en employait 240 001 ; une validation passant à 10^{-4} en valeur relative tout en mesurant une grandeur qui n'existe pas ; et un verdict tranché par la quatorzième décimale d'une comparaison flottante. Nous rapportons ensuite les contre-mesures qui ont tenu : tester les garde-fous eux-mêmes par mutation, détecter les marqueurs non substitués génériquement plutôt que par une liste écrite à la main, employer des expressions régulières plutôt que l'égalité de chaînes, brancher la réfutation avant la confirmation, et déclarer d'avance le sens de chaque substitution. Le coût du protocole est que les études s'arrêtent d'elles-mêmes ; sur ce corpus, cinq l'ont fait. Son bénéfice est que 69 affirmations ont été rétractées ou rétrogradées, dont plusieurs résultats phares du corpus, et la plupart par la machinerie de l'analyste plutôt que par un référé. Nous ne revendiquons aucune généralité au-delà de $N = 1$, et nous rapportons ce que le protocole *n'attrape pas*.

1 Le protocole

L'unité est un script. Son docstring s'ouvre sur un bloc intitulé CRITÈRES PRÉ-ENREGISTRÉS, qui contient : les validations à passer avant toute publication, les critères eux-mêmes — exigés *exhaustifs* et *exclusifs*, de sorte que chaque issue possible corresponde à exactement un verdict écrit — et une déclaration de ce que l'étude *ne* revendiquera *pas*.

Trois commandes opèrent dessus :

- **freeze** extrait le docstring par AST, le hache, et inscrit `chemin` → `sha256` dans un fichier de verrou ;
- **verify** recalcule et sort en code non nul si une empreinte a bougé — bloquant en intégration continue ;
- **freeze --amend** autorise un critère à changer, mais écrit l'ancienne et la nouvelle empreinte, avec une justification obligatoire, dans un fichier public de rétractations.

*github.com/Dantenos

Deux conséquences suivent immédiatement, et il faut les énoncer car elles sont tout l'objet. D'abord, modifier les critères *après* avoir vu le résultat n'est pas interdit : c'est *consigné*. Sur le corpus rapporté ici, le canal d'amendement a servi zéro fois : les 88 critères gelés portent tous l'empreinte de leur premier gel. Ensuite, le corps d'un script peut être corrigé librement ; seuls les critères sont immuables. Cette séparation est ce qui rend le protocole utilisable, et c'est aussi d'elle qu'est venue la première surprise.

2 La surprise : il attrape des critères, pas des résultats

Nous attendions du protocole qu'il attrape des résultats s'écartant de leur condition de succès. Il l'a fait rarement. Ce qu'il a attrapé, encore et encore, ce sont des critères *formellement satisfaisables sans rien établir*. Neuf modes distincts se sont produits, et aucun ne se réduit à de la négligence : chacun a été écrit par un analyste cherchant la rigueur, et chacun a passé une relecture au moment de son gel.

Deux modes supplémentaires sont apparus pendant la rédaction de cet article et appartiennent à la taxonomie, bien que nous ne les ayons pas numérotés :

- **une définition gelée divergeant de la définition opérante.** Un outil de vérification a été gelé avec une définition de région du ciel différant de 10° en ascension droite de celle que le corpus employait partout ailleurs. Il comptait 412 objets là où le corpus en comptait 416. L'outil avait raison sur le défaut qu'il venait de trouver, et tort sur la définition avec laquelle il l'avait trouvé.
- **une validation bloquée par sa propre résolution.** Un test exigeait qu'une incertitude rétrécisse d'un facteur k ; la grille de balayage ne pouvait pas résoudre une incertitude plus petite qu'un pas, donc à $k = 4$ le facteur mesuré valait 2,0 au lieu de 2,8–5,6. La validation a correctement refusé de conclure sur une mesure que son propre maillage ne pouvait pas rendre. Notons qu'une signature *indépendante* dans la même exécution — les gains en χ^2 suivant k^2 à trois décimales — établissait bien que la manipulation était opérante. Nous ne l'avons pas substituée : le faire est le mode 7 déguisé.

3 Ce qui marche vraiment

Les contre-mesures ci-dessous sont rapportées parce qu'elles ont tenu ; plusieurs solutions d'apparence plausible n'ont pas tenu.

Tester les garde-fous par mutation. Un outil de vérification qui rend « 55/55, aucun échec bloquant » n'établit rien tant qu'on n'a pas montré qu'il *peut* échouer. Nous avons injecté cinq fautes dans les fichiers qu'il lit — un gain gonflé de 5%, une moyenne pondérée de 2%, une valeur centrale déplacée, une incertitude multipliée par quatre, une fraction poussée hors bornes — en exigeant que les cinq soient attrapées. Les cinq l'ont été. Le 55/55 n'a acquis un sens qu'à ce moment-là. *Nous recommandons cette pratique comme obligatoire, non facultative*. C'est la contre-mesure directe du mode 8.

Détecter génériquement, jamais par liste écrite à la main. Un contrôle de substitution de gabarit énumérait cinq noms de marqueurs à la main. Un sixième a été ajouté au gabarit plus tard ; le contrôle est passé ; la page publiée a échoué dès la première ligne, tous marqueurs non substitués. Le contrôle qui l'a remplacé est une expression régulière unique sur `__[A-Z_]++` et ne peut pas manquer un marqueur dont il n'a jamais entendu parler. Règle générale : *un contrôle doit pouvoir détecter le cas auquel son auteur n'a pas pensé*.

Des expressions régulières, jamais l'égalité de chaînes, sur du texte. Un garde-fou écrit comme un test d'égalité contre une ligne de prose s'est brisé en silence quand le fichier a gagné un

saut de ligne. Tous les contrôles textuels du corpus sont désormais des regex insensibles aux sauts de ligne. C’est la règle 7 de la constitution du corpus, et elle a été écrite après la défaillance, pas avant.

Brancher la réfutation avant la confirmation. Lorsqu’une étude est conçue pour confirmer une lecture de l’analyste lui-même, le code évalue la branche qui la *réfuterait avant* celle qui la confirmerait, et le seuil de confirmation est plus strict que le seuil de réfutation (chez nous un facteur 3 contre un facteur 1). Deux fois cet ordre a compté : une de nos études a rendu EXPLICATION RÉFUTÉE sur un mécanisme que nous avions affirmé dans deux entrées successives sans jamais l’avoir testé.

Déclarer le sens de chaque substitution. Là où une valeur doit être supposée, le protocole exige qu’elle soit choisie *contre* la thèse défendue, et exige que le choix le dise. Un facteur de conversion de 0,8389 a été retenu contre un 0,8429 tout aussi défendable exactement sur ce motif ; énoncer la raison est ce qui distingue un choix conservateur d’un choix chanceux.

Laisser l’étude s’arrêter, et publier l’arrêt. Cinq études de ce corpus se sont arrêtées sur leurs propres validations sans rien publier. Chaque arrêt était instructif : l’un a révélé qu’une ancre était comparée au mauvais optimum, un autre qu’une grille ne pouvait pas résoudre ce qu’on lui demandait de mesurer. *Un protocole dont les études ne s’arrêtent jamais n’est pas appliqué.*

4 Coût et bénéfice

Le coût est réel. Des études s’arrêtent. Des critères raisonnables au moment de leur rédaction se révèlent mal posés et ne peuvent pas être réparés sur place — la règle du corpus est qu’un critère gelé est un *constat*, non une affirmation à réécrire, de sorte qu’un outil dépassé est remplacé plutôt qu’amendé, et que les deux restent au registre. Cela produit un encombrement visible, et nous tenons cet encombrement pour une qualité : le compte d’amendements est resté à zéro non parce que les critères étaient toujours justes, mais parce qu’avoir tort était survivable sans les modifier.

Le bénéfice se mesure sur un axe que nous pouvons rapporter honnêtement : 69 affirmations ont été réfutées, rétrogradées ou corrigées, et la majorité l’ont été par la machinerie de l’analyste. Plusieurs étaient des résultats phares :

- un modèle en tête d’une table comparative de 25 entrées devait 8,62 de ses 9,84 unités d’avance à un artefact d’étalonnage — après que trois audits « adversariaux » l’avaient validé sans jamais sortir du pipeline vicié ;
- une fraction de ciel s’est révélée fausse d’un facteur $\pi/2$, copiée à travers six générations d’artefacts, avec pour effet que le corpus *surestimait sa propre anomalie* de 57% ;
- un mécanisme que l’analyste avait affirmé dans deux entrées successives a été réfuté par le premier test qui lui ait jamais été appliqué.

Nous notons sans ironie que le troisième est le protocole fonctionnant exactement comme prévu, et l’analyste ne fonctionnant pas comme prévu.

5 Ce que le protocole n’attrape pas

Il est mécanique. Il ne lit pas les équations, ne juge pas la physique, et ne peut pas dire si un modèle est intéressant. Dans ce corpus, l’audit le plus conséquent n’a été déclenché par aucun outil mais par un lecteur humain disant que les résultats semblaient *trop beaux pour être vrais* ; cet audit a trouvé un minimum de bord (mode 5) que tous les contrôles automatiques avaient laissé passer. Plus tard, une vérification de littérature a tué net un article projeté en établissant que ses quatre résultats revendiqués étaient publiés, le plus ancien en 2015 et le plus récent quatre jours plus tôt. Ni l’un ni l’autre n’est atteignable par un hachage.

Il y a aussi un risque propre que le protocole crée. Puisque les critères sont immuables, il existe une pression à les écrire assez lâches pour être sûrs. Nous l'avons contrée en exigeant qu'ils soient *exhaustifs et exclusifs* — chaque issue nommée d'avance, y compris celles qui réfutent l'analyste — mais nous ne prétendons pas que la pression soit éliminée, seulement qu'elle est visible.

6 Reproductibilité

Le protocole tient en 120 lignes de Python et ne dépend que de la bibliothèque standard. Ses propres critères de succès sont gelés par lui-même (commit 0) : il réussit si **freeze** puis **verify** passent sur au moins deux scripts réels et si la falsification d'un critère est détectée par une sortie non nulle ; il échoue et n'est pas publié si un faux positif apparaît sur un fichier non modifié. Les deux conditions ont tenu sur 88 critères gelés.

#	mode de défaillance	ce qui s'est passé
1	paramètre non identifiable	Un critère a été gelé sur une grandeur que les données ne pouvaient pas contraindre. Toute issue le satisfaisait, donc il n'excluait rien.
2	borne inadaptée au découpage	Une borne de qualité d'ajustement de la forme $\chi^2/(N + 17)$ a été gelée pour un jeu à 22 intervalles. Le décalage venait d'une autre configuration de données et rendait la borne vide à ce N .
3	référence non optimisée	Une validation comparait le modèle en un point <i>fixé</i> à une référence prise à son <i>optimum</i> . L'écart mesuré était l'optimisation, pas la physique.
4	mauvais comparant	Une validation a été jouée contre un comparant qui réintroduisait un terme de rayonnement que le modèle avait retiré. Elle a échoué pour une raison étrange à l'hypothèse.
5	minimum de bord	Un critère rendait une contrainte très serrée. Le réexamen a montré que le minimum était sur le bord du domaine accessible : une branche du paramètre était fermée par l'implémentation, donc la contrainte était unilatérale tout en étant rapportée bilatérale.
6	exigences incompatibles	Deux contraintes ont été gelées dans le même bloc — une grille de 41 points et une tolérance de $\pm 0,3$ — qui ne pouvaient pas être satisfaites ensemble. L'étude ne pouvait pas réussir, par construction.
7	divergence docstring/code	Un docstring affirmait « une grille dense (60 000 points, log) » ; le code, après corrections successives du corps, en employait 240 001. Le critère aurait été satisfait par autre chose que ce qu'il énonçait.
8	un contrôle qui ne mesure rien	Une validation exigeait qu'un facteur de conversion soit constant à mieux que 2%. Elle a passé à 0,010%. La grandeur qu'elle convertissait n'existait pas : le paramètre source avait été mal lu, et il n'y avait aucun bras de levier à convertir. <i>Une validation qui passe parfaitement en mesurant un fantôme est plus dangereuse qu'une qui échoue.</i>
9	un verdict tranché par un arrondi	Deux seuils étaient comparés par $\geq$ sur une arithmétique de grille flottante. Les valeurs vraies étaient exactement 2 et exactement 1 ; les valeurs calculées 1,999999999999791 et 0,999999999999836. Les deux comparaisons ont échoué, et les deux échecs tombaient dans le sens qui arrangeait l'analyste.

TABLE 1 – Neuf façons dont un critère pré-enregistré a été formellement satisfait, ou formellement tranché, sans établir ce pour quoi il avait été écrit. Chaque ligne s'est produite dans un même corpus, en deux jours d'usage intensif.