

# Les critères pré-enregistrés sont des spécifications : onze défaillances observées dans une campagne de cosmologie, cartographiées sur des pathologies connues

Édouard Lantenois\*

Août 2026

## Résumé

Nous rapportons onze façons dont un critère de succès gelé par empreinte a échoué au cours d’une campagne intensive de cosmologie — 89 critères gelés, 201 entrées de registre, 81 attaques arbitrées en deux jours — et nous cartographions chacune sur une pathologie déjà nommée hors de notre domaine. **Aucune des onze n’est un mode de défaillance nouveau.** L’une d’elles — une validation passant à  $10^{-4}$  en valeur relative alors que la grandeur qu’elle convertit n’existe pas — est la *vacuité*, nommée par [Beer et al. \(1997\)](#) en 1997, dont l’exemple canonique (« toute requête est finalement acquittée », satisfaite par un système qui n’émet jamais de requête) est le nôtre avec une tolérance flottante à la place d’un opérateur temporel. Une autre est l’incohérence code-commentaire ; une autre un paramètre au bord du domaine physique ([Feldman & Cousins, 1998](#)) ; une autre une spécification insatisfiable ; une autre un test instable sur égalité flottante. Notre revendication est donc une *cartographie*, non une découverte : les critères d’acceptation pré-enregistrés sont des spécifications, et ils héritent de toute la pathologie connue des spécifications. Nous soutenons que cela mérite d’être énoncé parce que les taxonomies existantes de défaillance du pré-enregistrement ([Yamada, 2018](#) ; [Bakker et al., 2020](#)) sont *comportementales* — elles classent ce que fait un chercheur — alors que les défaillances observées ici sont *structurelles* : elles classent ce que le critère *est*, et chacune s’est produite sans la moindre malhonnêteté. Nous donnons le décompte des instances, la classe de chacune, et quel outillage existant l’aurait attrapée. Nous rapportons un invariant de protocole pour lequel nous n’avons trouvé aucune antériorité — le bloc des critères est immuable tandis que le corps du script reste librement modifiable — et nous renonçons explicitement à revendiquer le reste du protocole, qui est une intégration d’enregistrement à la OSF, d’intégration continue ([Beaulieu-Jones & Greene, 2017](#)) et de programmation par contrat. Enfin nous rapportons la seule défaillance qui n’est pas celle d’un critère : après trois conceptions gelées bloquées sur la même question, une quatrième serait passée, et l’écrire aurait été du p-hacking d’un cran au-dessus. Le gel par empreinte protège chaque étude ; il ne protège pas la série.

## 1 Le protocole, rapporté comme note de conception

Nous énonçons le mécanisme brièvement, et nous ne le revendiquons pas. L’unité est un script. Son docstring s’ouvre sur un bloc de critères de succès : les validations à passer avant toute publication, les critères eux-mêmes — exigés *exhaustifs* et *exclusifs*, de sorte que chaque issue corresponde à exactement un verdict écrit — et une déclaration de ce que l’étude ne revendiquera pas. `freeze` extrait le docstring par AST et enregistre son SHA-256 ; `verify` fait échouer l’intégration continue si l’empreinte a bougé ; les amendements sont permis mais consignés dans un journal public avec justification obligatoire.

---

\*[github.com/Dantenos](https://github.com/Dantenos)

Chaque composant est disponible sur étagère. Les critères dans l’artefact exécutable, c’est la programmation par contrat, et en Python spécifiquement c’est `doctest`. Geler un plan d’analyse par empreinte, c’est l’enregistrement OSF, et sous forme cryptographique OriginStamp (Gipp et al., 2018) et CryptSubmit (Gipp et al., 2017) ; une recherche dans OpenAlex rend de l’ordre d’une centaine de dépôts en physique et cosmologie le faisant déjà, dont plusieurs de 2026 combinant un manifeste SHA-256 et une attestation OpenTimestamps. L’application par intégration continue, c’est l’analyse continue (Beaulieu-Jones & Greene, 2017) et la convention Popper (Jimenez et al., 2017). Un journal d’amendement public avec justification, c’est le mécanisme de retrait d’OSF, et le signalement des déviations a sa propre littérature de guidage (Willroth & Atherton, 2024). Fixer les critères d’acceptation avant de regarder, c’est l’analyse aveugle, standard en physique des particules depuis vingt ans (Klein & Roodman, 2005; MacCoun & Perlmutter, 2015) et en cosmologie depuis DES (Muir et al., 2020).

**Le seul invariant que nous n’ayons pas trouvé ailleurs.** L’antériorité gèle l’*artefact* — le plan, le code, le manifeste. Nous ne gelons que le *prédicat d’acceptation*, et laissons le corps librement modifiable. Cette asymétrie est ce qui rend correction et pré-enregistrement compatibles : un script peut être débogué, reparamétré et relancé sans toucher à ce qui compterait comme un succès. Sur 89 critères gelés, le canal d’amendement a servi zéro fois — non parce que les critères étaient toujours justes, mais parce qu’avoir tort était survivable sans les modifier. Nous offrons cette asymétrie comme seule contribution du protocole et ne défendons rien de plus.

## 2 La thèse : les critères sont des spécifications

Un critère pré-enregistré est un prédicat qu’un calcul doit satisfaire pour qu’une affirmation compte comme établie. C’est la définition d’une spécification. La conséquence est immédiate et, autant que nous puissions le vérifier, jamais énoncée : **les critères scientifiques pré-enregistrés héritent de toute la pathologie connue des spécifications** — satisfaction vacue, insatisfiabilité, dérive vis-à-vis de l’implémentation, sensibilité insuffisante — ainsi que de la littérature de détection qui accompagne chacune.

Nous y sommes arrivés par le chemin long. Nous avons écrit onze critères qui ont échoué, nous les avons catalogués comme s’ils étaient neufs, et nous avons découvert en vérifiant que chacun portait déjà un nom.

## 3 Onze instances observées, et la classe de chacune

La table 1 est l’article. Trois remarques en découlent.

**La vacuité est celle qui devrait le plus inquiéter le praticien.** Beer et al. (1997) définissent la vacuité comme une spécification « satisfaite trop facilement, ou vacûment », et avertissent qu’elle « induit les utilisateurs de la vérification de modèles à croire qu’un système est correct ». Leur exemple canonique — « toute requête est finalement suivie d’un acquittement » est satisfaite vacûment par un système qui n’émet jamais de requête — est précisément notre instance, avec une tolérance à la place d’un opérateur temporel. Notre validation est passée à  $10^{-4}$  en valeur relative et n’a rien établi. *Un critère qui passe parfaitement en mesurant un fantôme est plus dangereux qu’un critère qui échoue*, et les méthodes formelles le savent depuis avant l’existence du mouvement du pré-enregistrement. À notre connaissance, c’est la première instance rapportée de vacuité dans un critère d’acceptation *scientifique* pré-enregistré ; c’est une revendication bien plus petite qu’un mode nouveau, et c’est la vraie.

**L’outillage existant aurait attrapé quatre des sept classes.** La dérive de spécification est détectable par les outils d’incohérence code–commentaire ; l’insatisfiabilité par un test de sa-

tisfiabilité sur le bloc de critères ; l'instabilité flottante par un lint ; la sensibilité insuffisante par la discipline d'ordre de précision de la vérification de code. La vacuité a des algorithmes dédiés. Rien de cet outillage n'est appliqué aujourd'hui aux critères scientifiques pré-enregistrés, et nous ne voyons aucune raison qu'il ne puisse pas l'être.

**Ce qu'aucun outillage n'aurait attrapé.** La non-identifiabilité, le minimum de bord et le comparant faible sont statistiques, non syntaxiques. Le minimum de bord en particulier n'a été trouvé que parce qu'un lecteur humain a remarqué qu'un résultat semblait *trop beau pour être vrai* ; tous les contrôles automatiques l'avaient laissé passer.

## 4 En quoi ceci diffère des taxonomies existantes

Yamada (2018) donne quatre façons de « craquer » le pré-enregistrement : le signalement sélectif, la ré-expérimentation infinie, la sur-émission, et le pré-enregistrement après connaissance des résultats. Bakker et al. (2020) énumèrent 29 degrés de liberté du chercheur et constatent que les formats structurés les réduisent sans les éliminer ; Claesen et al. (2021) audient l'adhésion dans la première génération d'études pré-enregistrées ; Wicherts et al. (2016) donnent une liste de 34 points.

Ce sont des taxonomies *comportementales* : elles classent ce que fait un chercheur, et leurs modes sont, selon le cadrage de Yamada lui-même, ce qu'un chercheur « malveillant » pourrait faire. Les défaillances que nous rapportons sont *structurelles*. Elles classent ce que le critère *est*, et chacune s'est produite sans malhonnêteté : chacune a été écrite par un analyste cherchant la rigueur, chacune a passé une relecture au moment de son gel, et plusieurs ont été attrapées par la machinerie de l'analyste lui-même des jours plus tard. Cette distinction est l'écart que nous revendiquons, et c'est le seul.

Une contiguïté n'est pas fortuite. La « ré-expérimentation infinie » de Yamada — répéter une expérience jusqu'à ce que les données coopèrent — est la sœur comportementale du §5, où ce sont les conceptions et non les jeux de données qui sont répétées jusqu'à ce que l'une passe. La ressemblance de famille est exacte ; l'objet diffère.

## 5 La défaillance qui n'est pas celle d'un critère

Une question de la campagne a été tentée trois fois. La première conception a bloqué sur un plancher de grille. La deuxième, à maillage dix fois plus fin, a bloqué parce que le plancher avait été *déplacé* et non levé. La troisième a remplacé l'estimateur par marche de grille par un ajustement parabolique auto-validé — qui a fonctionné, sans aucun plancher, son incertitude suivant  $\times 2,00$  puis  $\times 4,00$  exactement — et a bloqué parce que sa propre validation exigeait la reproduction exacte des valeurs *de grille* que le nouvel estimateur abandonnait délibérément. Ce dernier blocage relève de la classe « insatisfiabilité », et nous l'avons écrit après avoir catalogué cette classe.

Une quatrième conception tolérant un pas de grille serait passée ; toutes les autres validations passaient déjà, et la réponse qu'elle aurait rendue était visible dans la sortie de la troisième. Nous ne l'avons pas écrite.

**Le gel par empreinte protège chaque étude prise isolément et ne protège pas la série.** Ce qui est gelé, c'est chaque tentative, pas la décision de recommencer. Itérer les conceptions jusqu'à ce qu'une passe est du p-hacking d'un cran au-dessus, et le pré-enregistrement tel qu'il se pratique n'a aucune défense contre cela — chaque tentative est impeccablement pré-enregistrée. Le seul garde-fou que nous voyions est une règle d'arrêt déclarée. Nous en avons adopté une, *au troisième blocage sur une même question, on cesse et on consigne le statut non établi* ; nous notons qu'elle est arbitraire, que toute sa valeur tient à sa publicité, et que nous ne l'avons adoptée qu'après en avoir eu besoin. Le coût est réel : une signature restée strictement invariante sous une

incertitude quatre fois moindre demeure inopposable. Nous préférons ce coût à un verdict obtenu par sélection de conception.

## 6 Pratiques adoptées, et leur antériorité

Nous les listons par complétude et attribuons chacune ; aucune n'est de nous.

*Tester le vérificateur par mutation avant de croire son taux de réussite.* Un outil rendant « 55 sur 55, aucun échec bloquant » n'établit rien tant qu'on n'a pas montré qu'il peut échouer ; nous avons injecté cinq fautes en exigeant que les cinq soient attrapées. C'est le test par mutation (Jia & Harman, 2010) appliqué à l'oracle plutôt qu'au code, ce qui est Knauth et al. (2009) ; et muter les vérificateurs spécifiquement pour détecter la vacuité, c'est Vacuité par mutation (2010) — autrement dit la combinaison de notre classe « vacuité » avec cette pratique a été publiée en 2010. Elle a aussi été appliquée au logiciel scientifique (Hook & Kelly, 2009). Nous rapportons seulement l'avoir trouvée nécessaire.

*Détecter génériquement, jamais par liste écrite à la main.* Un contrôle de gabarit énumérant cinq noms de marqueurs à la main est passé pendant qu'un sixième, ajouté plus tard, restait non substitué et cassait la page publiée dès sa première ligne. Le contrôle qui l'a remplacé est une expression régulière unique et ne peut pas manquer un marqueur dont il n'a jamais entendu parler.

*Brancher la réfutation avant la confirmation,* et rendre le seuil de confirmation plus strict que celui de réfutation. Deux fois cet ordre a compté ; une fois il a rendu la réfutation d'un mécanisme que nous avons affirmé dans deux entrées de registre successives sans jamais l'avoir testé.

*Déclarer le sens de chaque substitution.* Là où une valeur doit être supposée, la choisir contre la thèse défendue, et dire que c'est pour cela.

## 7 Limites

$N = 1$  : un corpus, un analyste, deux jours. Nous ne pouvons rien dire de la distribution générale des onze instances, seulement qu'elles se sont produites et qu'aucune n'a exigé de mauvaise foi. Le décompte est le contenu empirique : 89 critères gelés, onze défaillances des espèces ci-dessus, et cinq études arrêtées sur leurs propres validations sans rien publier.

Le protocole est aussi mécanique. Il ne lit pas les équations et ne juge pas la physique. Dans cette campagne, l'audit le plus conséquent a été déclenché par un lecteur humain, et une vérification de littérature a tué net un article compagnon en établissant que ses quatre résultats revendiqués étaient déjà publiés — le plus ancien en 2015, le plus récent quatre jours plus tôt. Ni l'un ni l'autre n'est atteignable par un hachage. C'est une vérification du même genre qui a produit la forme finale de cet article : elle a établi qu'aucune de nos onze défaillances n'était un mode nouveau, et l'article s'en trouve meilleur.

## Références

- Andrae, R., Schulze-Hartung, T., & Melchior, P. 2010, [arXiv:1012.3754](#)
- Bakker, M., et al. 2020, PLOS Biology, 18, e3000937, [doi:10.1371/journal.pbio.3000937](#)
- Beaulieu-Jones, B. K., & Greene, C. S. 2017, Nature Biotechnology, 35, 342, [doi:10.1038/nbt.3780](#)
- Beer, I., Ben-David, S., Eisner, C., & Rodeh, Y. 1997, in CAV 1997, [doi:10.1007/3-540-63166-6\\_28](#)
- Claesen, A., et al. 2021, Royal Society Open Science, 8, 211037, [doi:10.1098/rsos.211037](#)

- Ferrari Dacrema, M., Cremonesi, P., & Jannach, D. 2019, in RecSys 2019, doi:10.1145/3298689.3347058
- Feldman, G. J., & Cousins, R. D. 1998, Phys. Rev. D, 57, 3873, doi:10.1103/PhysRevD.57.3873
- Gipp, B., Breitinger, C., Meuschke, N., & Beel, J. 2017, in JCDL 2017, doi:10.1109/JCDL.2017.7991588
- Gipp, B., et al. 2018, it — Information Technology, 60, 47, doi:10.1515/itit-2018-0020
- Hook, D., & Kelly, D. 2009, in ICSE SECSE 2009, doi:10.1109/SECSE.2009.5069163
- Jia, Y., & Harman, M. 2010, IEEE Trans. Softw. Eng., 37, 649, doi:10.1109/TSE.2010.62
- Jimenez, I., et al. 2017, in IPDPSW 2017, doi:10.1109/IPDPSW.2017.157
- Klein, J. R., & Roodman, A. 2005, Ann. Rev. Nucl. Part. Sci., 55, 141, doi:10.1146/annurev.nucl.55.090704.151521
- Knauth, T., Fetzner, C., & Felber, P. 2009, in ICSTW 2009, doi:10.1109/ICSTW.2009.40
- Kupferman, O., & Vardi, M. Y. 2003, STTT, 4, 224, doi:10.1007/s100090100062
- Luo, Q., Hariri, F., Eloussi, L., & Marinov, D. 2014, in FSE 2014, doi:10.1145/2635868.2635920
- MacCoun, R., & Perlmutter, S. 2015, Nature, 526, 187, doi:10.1038/526187a
- Muir, J., et al. 2020, MNRAS, 494, 4454, doi:10.1093/mnras/staa965
- Panthaplackel, S., et al. 2021, in AAAI 2021, doi:10.1609/aaai.v35i1.16119
- Roache, P. J. 1998, AIAA Journal, 36, 696, doi:10.2514/2.457
- Rozier, K. Y., & Vardi, M. Y. 2007, in SPIN 2007, doi:10.1007/978-3-540-73370-6\_11
- Salari, K., & Knupp, P. 2000, rapport Sandia SAND2000-1444, doi:10.2172/759450
- 2010, « Vacuity analysis for property qualification by mutation of checkers », in DATE 2010, doi:10.1109/DATE.2010.5457158
- Wicherts, J. M., et al. 2016, Frontiers in Psychology, 7, 1832, doi:10.3389/fpsyg.2016.01832
- Willroth, E. C., & Atherton, O. E. 2024, AMPPS, 7, doi:10.1177/25152459231213802
- Yamada, Y. 2018, Frontiers in Psychology, 9, 1831, doi:10.3389/fpsyg.2018.01831

| instance observée                                                                                                                                                                                                                                                                    | classe nommée                                                                              | d'où vient le nom                                                                                                                                                                              |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Critère gelé sur une grandeur que les données ne peuvent pas contraindre; satisfait par toute issue.                                                                                                                                                                                 | <b>Non-identifiabilité</b>                                                                 | théorie de l'estimation, standard                                                                                                                                                              |
| Une borne de qualité d'ajustement $\chi^2/(N+17)$ gelée pour un jeu à 22 intervalles; le décalage venait d'une autre configuration de données.                                                                                                                                       | <b>Mésusage du <math>\chi^2</math> ré-duit</b>                                             | <a href="#">Andrae et al. (2010)</a>                                                                                                                                                           |
| Une validation comparant le modèle en un point <i>fixé</i> à une référence prise à son <i>optimum</i> ; l'écart mesuré était l'optimisation.<br>Une validation jouée contre un comparant qui réintroduisait un terme que le modèle avait retiré.                                     | <b>Comparant faible ou inadapté</b> — ces deux-là n'en font qu'une, et un référé le dirait | <a href="#">Ferrari Dacrema et al. (2019)</a> ; le domaine « biais de comparant » des instruments cliniques de risque de biais                                                                 |
| Une contrainte serrée dont le minimum était sur le bord du domaine accessible; une branche était fermée par l'implémentation, donc un résultat unilatéral était rapporté bilatéral.                                                                                                  | <b>Paramètre au bord physique</b>                                                          | <a href="#">Feldman &amp; Cousins (1998)</a> , dont c'est le sujet entier : intervalles uni- contre bilatéraux au bord                                                                         |
| Deux exigences gelées dans un même bloc — une grille de 41 points et une tolérance de $\pm 0,3$ — qui ne pouvaient pas être satisfaites ensemble. L'étude ne pouvait pas réussir par construction.                                                                                   | <b>Spécification insatisfiable</b>                                                         | <a href="#">Rozier &amp; Vardi (2007)</a> ; le test de satisfiabilité est le contrôle de bon sens standard                                                                                     |
| Un docstring affirmant « une grille dense (60 000 points, log) » quand le code, après corrections successives du corps, en employait 240 001.<br>Un outil de vérification gelé avec une définition de région du ciel différant de $10^\circ$ en ascension droite de celle du corpus. | <b>Dérive de spécification</b> / incohérence code-commentaire                              | <a href="#">Panthaplackel et al. (2021)</a> , et un sous-domaine de détection actif                                                                                                            |
| Une validation exigeant un facteur de conversion constant à 2%; elle a passé à 0,010%. La grandeur qu'elle convertissait n'existait pas.                                                                                                                                             | <b>Vacuité</b>                                                                             | <a href="#">Beer et al. (1997)</a> ; <a href="#">Kupferman &amp; Vardi (2003)</a> ; vingt-cinq ans d'algorithmes de détection                                                                  |
| Deux seuils comparés par $\geq$ sur une arithmétique de grille flottante; valeurs vraies exactement 2 et 1, valeurs calculées 1,999999999999791 et 0,9999999999999836. Les deux ont échoué, les deux dans le sens qui arrangeait l'analyste.                                         | <b>Test instable</b> , égalité flottante                                                   | <a href="#">Luo et al. (2014)</a> ; un lint standard                                                                                                                                           |
| Une validation exigeant qu'une incertitude rétrécisse d'un facteur $k$ ; la grille ne pouvait pas résoudre une incertitude sous un pas, donc l'exigence reculait                                                                                                                     | <b>Sensibilité de test insuffisante</b> 6                                                  | la vérification de code emploie l'ordre de précision sous raffinement de grille, pas une tolérance à grille unique ( <a href="#">Salari &amp; Knupp, 2000</a> ; <a href="#">Roache, 1998</a> ) |